## Sieć na perceptronie z biblioteki sklearn

1. Importujemy potrzebne biblioteki:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.linear_model import Perceptron
```

2. Tworzymy klasę Network:

```
• • •
class Network:
        self.perceptrons = []
        for i in range(10):
            self.perceptrons.append(Perceptron(eta0=eta, max_iter=n_iter,
random_state=random_state))
        for i in range(10):
            self.perceptrons[i].fit(X, Y[i])
    def show(self, X):
        fig, ax = plt.subplots(nrows=2, ncols=5, figsize=(5.25, 3))
        for i in range(2):
            for j in range(5):
                for y in range(7):
                     for x in range(5):
                        if letter[y * 5 + x] == 1:
                ax[i, j].set_xticklabels([])
ax[i, j].set_yticklabels([])
        plt.show()
    def predict(self, X):
            for i in range(len(self.perceptrons)):
                self.predicted.append(self.perceptrons[i].predict(X))
            for i in range(len(self.perceptrons)):
                self.predicted[i] = self.perceptrons[i].predict(X)
    def misclassified(self, Y):
        print("misclassified examples: %d" % (np.array(self.predicted) != Y).sum())
```

3. Tworzymy funkcję, dzięki której będziemy mogli uszkadzać dane wejściowe(kody liter) o potrzebny nam procent:

```
def damage(X, percent, seed=1):
    rgen = np.random.RandomState(seed)
    result = np.array(X)
    count = int(X.shape[1] * percent / 100)

for index_example in range(len(X)):
    order = np.sort(rgen.choice(X.shape[1], count, replace=False))
    for index_pixel in order:
        result[index_example][index_pixel] *= -1

return result
```

4. Wczytujemy i wybieramy potrzebne dane:

```
[120] df = pd.read_csv('data.csv', header=None)
[121] X = df.iloc[[5, 10, 11, 12, 14, 16, 17, 19, 22, 24], 0:35].values
    Y = df.iloc[0:10, 35:45].values
```

5. Wyświetlamy wybrane dane:

```
0
Χ
1, 1, 1],
 -1, -1, 1],
[-1, 1, 1,
-1, -1, -1,
   1, 1, 1],
[1, 1, 1,
1, 1, 1,
   1, -1, -1],
 1, 1, -1, 1, -1, 1, -1, 1, -1, 1, -1, 1,
```

6. Korzystając z metody show() klasy network wyświetlamy dane graficznie:



7. Tworzymy obiekt naszej sieci, przeprowadzamy uczenie. Na koniec wyświetlamy wyniki predict na zbiorze uczącym:

```
[146] network = Network()
    network.fit(X, Y)
    network.predict(X)

network.predicted

[array([ 1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, 1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, 1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, 1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, 1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] ),
    array([-1, -1, -1, -1, -1, -1, -1, -1, -1] )]
```

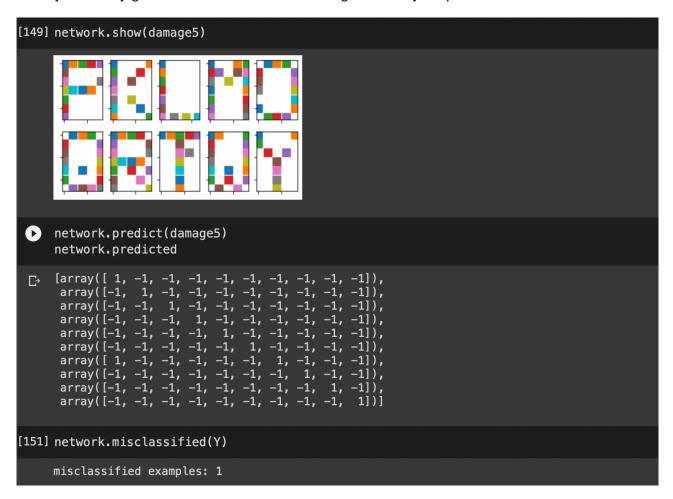
8. Wyświetlamy wynik misclassified na zbiorze uczącym:

```
[147] network.misclassified(Y)
misclassified examples: 1
```

9. Korzystając z funkcji damage uszkadzamy kolejno 5%, 15%, 40% danych i zapisujemy te dane do odpowiednich zmiennych:

```
[148] damage5 = damage(X, 5)
    damage15 = damage(X, 15)
    damage40 = damage(X, 40)
```

10. Wyświetlamy graficznie dane dla zbioru damage5 oraz wyniki predict i misclassified:



11. Wyświetlamy graficznie dane dla zbioru damage15 oraz wyniki predict i misclassified:

12. Wyświetlamy graficznie dane dla zbioru damage40 oraz wyniki predict i misclassified:

